

第六章 解线性方程组的迭代解法

6.1 Picard 迭代回顾

内容 有 $f(x) = 0$ ，将其化为等价方程 $x = \varphi(x)$ ，选取初值 x_0 ，令 $x_k = \varphi(x_{k-1})$ ，则有 $\lim_{k \rightarrow \infty} x_k = x^*$

x^* 即为原方程的解。 $|e_k| = |x_k - x^*| \leq \frac{L^k}{1-L} |x_1 - x_0|$

向量的迭代公式 对于 **线性方程组** $Ax = b$ ，可以写为 **等价方程组** $x = Bx + f$
为此构造序列 $x^{(k+1)} = Bx^{(k)} + f$
要考虑 **向量列的收敛性、收敛速度、误差** 等内容，和 B 有关。
收敛性判断：迭代过程中前后两次的距离越来越小。

6.2 基本概念

6.2.1 向量与矩阵的范数

考虑问题 1. 能否定义 **一个函数（映射）** 将 **向量或者矩阵** 投影成 **一个实数**？
2. 如果存在这个映射，这个映射应该满足什么性质？
3. 作为 **距离函数** 应该满足什么性质？ 正定性、齐次性、三角不等式

6.2.1.1 向量范数

定义 1 设 V 为线性空间， V 上的实值函数 $N(x) = \|x\|$ 满足：

- ① **正定性**： $\forall x \in V: \|x\| \geq 0$ 且 $\|x\| = 0 \Leftrightarrow x = 0$ **当且仅当零向量时为零**（不存在负距离）
 - ② **齐次性**： $\forall k \in R, \forall x \in V: \|kx\| = |k| \|x\|$ 空间中任意向量模长伸缩，不存在负距离，加绝对值
 - ③ **三角不等式**： $\forall x, y \in V: \|x + y\| \leq \|x\| + \|y\|$ **三角形中边长关系**
- 则称 $N(x) = \|x\|$ 为 V 上向量 x 的范数

性质 ① 若 $x \neq 0$ ， $\left\| \frac{x}{\|x\|} \right\| = 1$ ② $\|-x\| = \|x\|$ ③ $\left| \|x\| - \|y\| \right| \leq \|x - y\|$

常用范数 基本条件 $\forall x = (x_1, x_2, \dots, x_n) \in R^n (C^n)$

- ① **欧式范数（2-范数）** $\|x\|_2 = \sqrt{\sum_{i=1}^n |x_i|^2} = \sqrt{\sum_{i=1}^n \bar{x}_i x_i}$ 模长
- ② **最大模范数（ ∞ -范数）** $\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|$ 绝对值最大的一个
- ③ **绝对值范数（1-范数）** $\|x\|_1 = \sum_{i=1}^n |x_i|$ 绝对值之和（曼哈顿距离）
- ④ **p 范数** $\|x\|_p = (\sum_{i=1}^n |x_i|^p)^{\frac{1}{p}}$

注意 ① 可以证明上述定义均满足向量的范数定义
② 2-范数和1-范数都是 p -范数的特例
③ ∞ -范数也是 p -范数的特例（ $p \rightarrow \infty, \|x\|_p \rightarrow \|x\|_\infty$ ）
④ 范数可以认为是函数的函数。

A 的 F 范数 如果认为 $m \times n$ 矩阵是一个 $m \times n$ 维的向量， $\forall A_{m \times n}: \|A\|_2 = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2} \triangleq \|A\|_F$
一般 **不能简单的** 认为矩阵就是向量

6.2.1.2 矩阵范数

条件 简化起见, 先考虑方阵情况

定义 2 若 $\forall A_{n \times n}$ 对应一个实数 $\|A\|$, 满足有:

- ① $\|A\| \geq 0$, 且 $\|A\| = 0 \Leftrightarrow A = 0$
- ② $\|kA\| = |k|\|A\|$
- ③ $\|A + B\| \leq \|A\| + \|B\|$
- ④ $\|AB\| \leq \|A\|\|B\|$

则称 $\|A\|$ 为方阵的范数: **矩阵范数** 例如: **F范数**为矩阵范数, 行列式不是范数

注意 矩阵理化及运算常要考虑**矩阵与向量的乘积**, 我们希望范数 $\|Ax\|_{\text{向量范数}} \leq \|A\|_{\text{矩阵范数}} \|x\|_{\text{向量范数}}$ 由向量范数出发, 寻找矩阵范数, 使得满足条件。则称矩阵范数为由向量范数诱导出的范数。

定义 3 设 $\|\cdot\|$ 为向量范数, $\|\cdot\|_M$ 为矩阵范数。若 $\forall A \in R^{n \times n}, \forall x \in R^n \Rightarrow \|Ax\| \leq \|A\|_M \|x\|$ 则称 $\|A\|_M$ 为与向量范数 $\|\cdot\|$ **相容的矩阵范数**

例如, $\|A\|_F$ 与 $\|\cdot\|_1$ 不相容, 如果 $A = \begin{pmatrix} 1 & 4 \\ 1 & 4 \end{pmatrix} \quad x = \begin{pmatrix} 0 \\ 2 \end{pmatrix}$

定义 4 设 $\forall A \in R^{n \times m}$, $\|\cdot\|$ 为向量范数, 称 $\|A\| = \max_{x \in R^n, x \neq 0} \frac{\|Ax\|}{\|x\|}$ 为**矩阵A的算子范数 (诱导范数)**

注意 ① $\|A\| = \max_{\|x\|=1} \|Ax\|$

② 可以证明算子范数满足矩阵范数的4个条件. 故为矩阵范数.

③ 矩阵范数**不一定**都是算子范数, 如F-范数.

④ 算子范数与向量范数相容。($\|A\| = \max_{\|x\|=1} \frac{\|Ax\|}{\|x\|}$, $\|Ax\| = \frac{\|Ax\|}{\|x\|} \|x\| \leq \|A\| \|x\|$)

常用范数

① **行范数** $\|A\|_{\infty} = \max_{\|x\|=1} \|Ax\|_{\infty} = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$ 行范数(每行相加, 取最大)

② **列范数** $\|A\|_1 = \max_{\|x\|=1} \|Ax\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$ 列范数(每列相加, 取最大)

③ **2范数** $\|A\|_2 = \max_{\|x\|=1} \|Ax\|_2 = \sqrt{\lambda_{\max}(A^T A)}$ 难以计算, 但很有用

其中 $\lambda_{\max}(A^T A)$ 为矩阵 $A^T A$ 的绝对值最大的特征值

例题 设 $A = \begin{pmatrix} 1 & 2 & 0 \\ -1 & 2 & -1 \\ 0 & 1 & 1 \end{pmatrix}$, 求它的三个范数

$$\|A\|_1 = \max\{2, 5, 2\} = 5 \quad \|A\|_{\infty} = \max\{3, 4, 2\} = 4$$

$$A^T A = \begin{pmatrix} 2 & 0 & 1 \\ 0 & 9 & -1 \\ 1 & -1 & 2 \end{pmatrix} \Rightarrow |\lambda I - A^T A| = \begin{vmatrix} \lambda - 2 & 0 & -1 \\ 0 & \lambda - 9 & 1 \\ -1 & 1 & \lambda - 2 \end{vmatrix} = 0 \quad \text{则 } \lambda^3 - 13\lambda^2 + 38\lambda - 25 = 0$$

可得: $\lambda_1 = 9.14, \lambda_2 = 2.92, \lambda_3 = 0.9331$ 即 $\|A\|_2 = \sqrt{9.14} = 3.023$

定义 5 设 $\lambda_i (i = 1, 2, \dots, n)$ 为 $A \in R^{n \times n}$ 的n个特征值, 称 $\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|$ 为**A的谱半径**

$\rho(A) \leq \|A\|_p$ **谱半径小于任意的范数**, 可用于估计特征值的上界

定理 若 $\|A\| < 1$, 则 $I + A$ 可逆, 且 $\|(I + A)^{-1}\| \leq \frac{1}{1 - \|A\|}$

① 因为 $\|A\| < 1$, 所以 $\rho(A) < 1 \Rightarrow \pm 1$ 不是A的特征值, 所以 $I + A$ 可逆

② 令 $D = (I + A)^{-1}$, 则 $1 = \|I\| = \|(I + A)D\| = \|D + AD\| \geq \|D\| - \|AD\| \geq \|D\| - \|A\|\|D\| = \|D\|(1 - \|A\|)$ 因为